CHARGEGRID HUB / GUIA DE CONFIGURAÇÃO

Assistente de Operação com Ollama

Abra **Assistente de Operação** no painel, escolha o período e clique em **Gerar relatório**. A IA interpreta os dados e sugere próximos passos para o dono, com prioridade, motivo, resultado esperado e evidências. **Baixar relatório** exporta Markdown.

Configuração

O Ollama roda no mesmo computador do backend. Não exige conta ou chave de API. Instale pelo site oficial e baixe o modelo:

```
ollama pull qwen2.5:3b
```

O download inicial ocupa aproximadamente 1,9 GB. Depois, as análises locais funcionam sem internet. A velocidade depende do computador. Os padrões abaixo funcionam sem alterar `server/.env`:

```
AI_PROVIDER=ollama
OLLAMA_BASE_URL=http://127.0.0.1:11434
OLLAMA_MODEL=qwen2.5:3b
```

Para iniciar somente com recursos locais, feche o aplicativo Ollama e execute:

```
$env:OLLAMA_NO_CLOUD = '1'
ollama serve
```

Se houver runtime portátil em `server/storage/ollama/runtime`, o comando `powershell -File server/start-ollama.ps1` o inicia com nuvem desativada e modelos armazenados em `server/storage/ollama/models`. Também encontra uma instalação normal. Baixe o modelo em outro terminal usando o executável indicado.

Reinicie o backend após alterar configurações. `AI_PROVIDER=rules` desativa a IA. `OPENAI_API_KEY` e `OPENAI_MODEL` são ignorados: não há fallback para API paga.

Tablet

Mantenha o computador com backend e Ollama ligados. No tablet conectado à mesma rede, abra `http://IP-DO-COMPUTADOR:3001/admin.html`. O computador executa a IA e retorna o relatório. Não instale Ollama no tablet nem exponha sua porta na rede. O firewall deve permitir a porta do painel na rede privada.

Dados e limites

- Sessões encerradas são filtradas pelo calendário de São Paulo. Duplicatas e sessões ambiente são excluídas.
- Energia, bateria, pausas e custo do totem são simulados. Valor calculado não representa faturamento recebido nem lucro.
- SEMS+ é importação separada, filtrada pela data exibida no portal. Não é telemetria ao vivo e não é somada às estimativas do totem.
- Potência, ocupação e geração atuais são um retrato do simulador, não uma média histórica. Faltam fila, demanda não atendida, causa de interrupção e custos operacionais para fundamentar decisões de expansão.

Indicadores qualitativos derivados dos dados agregados são enviados à API local `/api/chat`, com JSON Schema e temperatura zero. Os valores e datas exatos ficam no servidor e na interface, evitando arredondamento ou repetição pelo modelo. A integração rejeita endereços externos, redirecionamentos e modelos identificados como remotos ou de nuvem. Referências e campos são validados; algarismos nos textos gerados são rejeitados, pois os números exibidos são calculados pelo servidor. Confira as evidências: isso não garante que toda interpretação do modelo esteja correta.

Se Ollama estiver desligado, o modelo ausente ou a resposta inválida, o relatório por regras continua disponível e identificado como **sem IA**.

`GET /api/reports/status` informa conexão e disponibilidade do modelo. `POST /api/reports/generate` aceita `{ "period": "today" | "week" | "month" }`. Uma geração por vez, timeout de três minutos e cache de IA por um minuto. Falhas não ficam em cache: a próxima tentativa pode funcionar após ligar Ollama. O relatório não altera carregadores ou tarifas.

Testes: `node --test server/test/*.test.js`. Testes automatizados usam respostas controladas; inferência real exige modelo instalado.

Referências: chat, saída estruturada, modo sem nuvem, Qwen.